Jump-point PLP (JPLP) simulation

Miao Cai miao.cai@slu.edu

2020-04-08

Contents

1	Power law process (PLP)		1	
	1.1	PLP intensity function	1	
	1.2	PLP simulation	1	
2	2 Jump Power Law Process (JPLP)		4	
	2.1	JPLP intensity function	4	
	2.2	JPLP simulation	4	

1 Power law process (PLP)

1.1 PLP intensity function

Power law process (PLP): When the intensity function of a NHPP is:

$$\lambda(t) = \frac{\beta}{\theta} \left(\frac{t}{\theta}\right)^{\beta-1} = \beta \theta^{-\beta} t^{\beta},$$

where $\beta > 0$ and $\theta > 0$, the process is called the power law process (PLP). The mean function $\Lambda(t)$ is the integral of the intensity function:

$$\Lambda(t) = \int_0^t \lambda(t) dt = \int_0^t \frac{\beta}{\theta} \left(\frac{t}{\theta}\right)^{\beta-1} = \left(\frac{t}{\theta}\right)^{\beta}$$

1.2 PLP simulation

```
t = t[c(-1, -length(t))]
  return(t)
}
\# simulate multiple NHPPs - time truncated case
sim_mul_plp_tau = function(n_shift = 20,
                           shift_len_mean = 20, shift_len_sd = 5,
                           theta = 10, beta = 2, mean_n = 5){
  tau_vector = rnorm(n_shift, shift_len_mean, shift_len_sd)#difference1
  t_list = list()
  len list = list()
  # end_time1 = list() # not needed for time truncated case
  for (i in 1:n_shift) {
    t_list[[i]] = sim_plp_tau(tau_vector[i], beta, theta)
    len_list[[i]] = length(t_list[[i]])
  event_dat = data.frame(
   shift_id = rep(1:n_shift, unlist(len_list)),
   event_time = Reduce(c, t_list)
  )
  start_end_dat = data.frame(
   shift_id = 1:n_shift,
   start_time = rep(0, n_shift),
    end_time = tau_vector #difference2
  )
  return(list(event_dat = event_dat,
              start_end_dat = start_end_dat,
              shift_length = unlist(len_list)))
}
sim_hier_plp_tau = function(N, beta = 1.5, theta){
  t_list = list()
  len_list = list()
  tau_vector = rnorm(N, 10, 1.3)
  for (i in 1:N) {
    t_list[[i]] = sim_plp_tau(tau_vector[i], beta = beta, theta = theta[i])
    len_list[[i]] = length(t_list[[i]])
```

```
}
  event_dat = data.frame(
    shift_id = rep(1:N, unlist(len_list)),
    event_time = Reduce(c, t_list)
  )
  start_end_dat = data.frame(
   shift_id = 1:N,
   start_time = rep(0, N),
    end_time = tau_vector #difference2
  return(list(event_dat = event_dat,
              start_end_dat = start_end_dat,
              shift_length = unlist(len_list)))
}
plot_est = function(data, var = "beta", hline_var = 1.5){
  p = data %>%
    filter(term == var) %>%
    ggplot(aes(id, est_mean)) +
    geom_point() +
    geom_line(linetype = "dashed", color = "red")+
    geom_errorbar(aes(ymax = est_mean + 1.96*est_sd,
                      ymin = est_mean - 1.96*est_sd),
                  width = 1)+
    geom_segment(aes(x = 10, xend = 100,
                     y = hline_var, yend = hline_var),
                 color = "green")+
    scale_x_continuous(breaks = c(0, 10, 25, 50, 75, 100),
                       labels = c("0", "10", "25", "50", "75", "100")) +
    labs(x = "The number of drivers (random effects)",
         v = var) +
    theme_bw()
  return(p)
}
# plot events
plot_events = function(event_dat, start_end_dat, cross_size = 2){
  p = event_dat %>%
    ggplot(aes(x = event_time, y = shift_id)) +
    geom_point(alpha = 0.8, shape = 4, color = 'red', size = cross_size) +
    scale_y_continuous("shift ID",
                       labels = as.character(start_end_dat$shift_id),
                       breaks = start_end_dat$shift_id)+
   xlab('Time to event (minutes)') +
```

2 Jump Power Law Process (JPLP)

2.1 JPLP intensity function

A Bayesian hierarchical JPLP has the following intensity function:

$$\lambda_{\text{JPLP}}(t|d, s, r, \beta, \gamma_{0,d}, \gamma, \mathbf{X}_d, \mathbf{W}) = \begin{cases} \kappa^0 \lambda(t|\beta, \gamma_{0,d}, \gamma, \mathbf{X}_d, \mathbf{W}) & 0 \le t \le a_{d,s,1} \\ \kappa^1 \lambda(t|\beta, \gamma_{0,d}, \gamma, \mathbf{X}_d, \mathbf{W}) & a_{d,s,1} \le t \le a_{d,s,2} \\ \dots & \dots \\ \kappa^{R-1} \lambda(t|\beta, \gamma_{0,d}, \gamma, \mathbf{X}_d, \mathbf{W}) & a_{d,s,R-1} \le t \le a_{d,s,R} \end{cases}$$

$$= \kappa^{r-1} \lambda(t|d, s, r, \kappa, \beta, \gamma_{0,d}, \gamma, \mathbf{X}_d, \mathbf{W}) \quad a_{d,s,r-1} \le t \le a_{d,s,r},$$

$$(1)$$

where the introduced parameter κ is the percent of intensity function recovery once the driver takes a break. We assume that this κ is constant across drivers and shifts.

2.2 JPLP simulation

Let T_1, T_2, \ldots be random variables representing the event times of a nonhomogeneous Poisson process with continuous expectation function $\Lambda(t)$, and let N_t represent the total number of events occurring before time t in the process. Then, conditional on the number of events $N_{t_0} = n$, the event times T_1, T_2, \ldots, T_n are distributed as order statistics from a sample with distribution function $F(t) = \Lambda(t)/\Lambda(t_0)$ for $t \in [0, t_0]$.

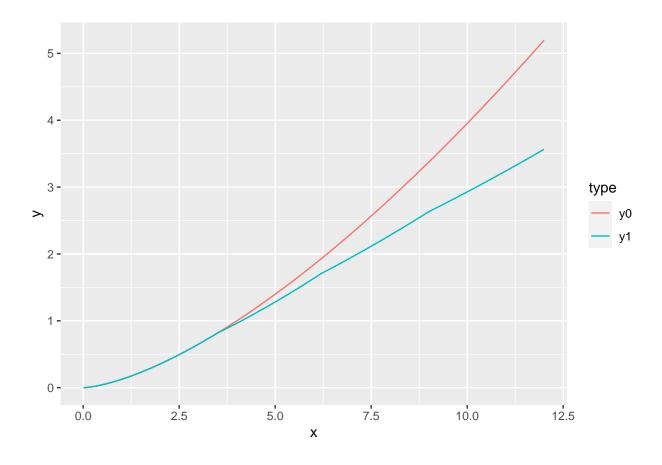
This is a generalization of the result for homogeneous Poisson processes. It naturally gives rise to the following algorithm for generating random variates from a nonhomogeneous Poisson process with expectation function $\Lambda(t)$ in a fixed interval $[0, t_0]$.

- (1) Generate $n \sim \text{Poisson}(\Lambda(t_0))$.
- (2) Independently generate n random variates t'_1, t'_2, \dots, t'_n from the cdf $F(t) = \Lambda(t)/\Lambda(t_0)$.
- (3) Order t'_1, t'_2, \dots, t'_n to obtain $t_1 = t'_{(1)}, t_2 = t'_{(2)}, \dots, t_n = t'_{(n)}$.
- (4) Deliver $t_1, t_2, ..., t_n$.

2.2.1 Mean function $\Lambda(t)$

```
t_{trip} = c(3.5, 6.2, 9),
                                                           beta = 1.5,
                                                           theta = 4)
       t_{trip1} = c(0, t_{trip})
      n_trip = length(t_trip1)
       comp = L_plp(t_trip, beta, theta)
       kappa_vec0 = rep(kappa, n_trip - 1)^(0:(n_trip - 2))
       kappa_vec1 = rep(kappa, n_trip - 1)^(1:(n_trip - 1))
       cum_comp0 = comp*kappa_vec0
       cum_comp1 = comp*kappa_vec1
       index_trip = max(cumsum(t > t_trip1)) - 1
       if(index_trip == 0){
             return((t/theta)^beta)
       }else{
              return(sum(cum_comp0[1:index_trip]) - sum(cum_comp1[1:index_trip]) +
                                           kappa^index_trip*(t/theta)^beta)
       }
 # test Lambda
kappa = 0.8
t_{trip} = c(3.5, 6.2, 9)
beta = 1.5
theta = 4
Lambda(3.1)
## [1] 0.6822642
L_plp(3.1)
## [1] 0.6822642
Lambda(4.1)
## [1] 0.9938842
kappa^0*L_plp(t_trip[1]) +
       \label{local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_local_loc
## [1] 0.9938842
Lambda(8.9)
## [1] 2.596555
kappa^0*L_plp(t_trip[1]) +
       kappa^1*L_plp(t_trip[2]) - kappa^1*L_plp(t_trip[1]) +
       kappa^2*L_plp(8.9) - kappa^2*L_plp(t_trip[2])
## [1] 2.596555
```

Lambda(12) ## [1] 3.564885 kappa^0*L_plp(t_trip[1]) + kappa^1*L_plp(t_trip[2]) - kappa^1*L_plp(t_trip[1]) + kappa^2*L_plp(t_trip[3]) - kappa^2*L_plp(t_trip[2]) + kappa^3*L_plp(12) - kappa^3*L_plp(t_trip[3]) ## [1] 3.564885 pacman::p_load(ggplot2, dplyr, tidyr) beta = 1.5theta = 4x = seq(0.01, 12, 0.01) $y0 = (x/theta)^beta$ y1 = rep(NA_real_, length(x)) for (i in 1:length(x)) { y1[i] = Lambda(t = x[i])} data.frame(x, y0, y1) %>% tidyr::pivot_longer(cols = c('y0', 'y1'), names_to = "type", values_to = 'y') %% ggplot(aes(x = x, y = y, group = type, color = type)) + geom_line()



2.2.2 Simulation JPLP events